Paper2Video
从论文方法到教学实践

模型如何配置？生成结果如何评估？

15分钟 / 模型分工 → 证据评价 → 人工决策

课堂目标：判断一段教学视频是否值得继续生成和使用。

论文解决什么问题？课堂需要什么？

101

组论文—作者演示视频
平均时长 6分15秒

Paper2Video：基准与任务
PaperTalker：生成框架

挑战：长文档、密集图表与公式
课件、字幕、声音、光标、人物需要对齐

01 课前

看短视频，带着问题学习

02 课中

复核错题，讨论例题

03 课后

修订材料，比较版本

基准统计来自论文§3.2；翻转课堂流程为本次展示设计。

四个 Builder，串起多模态生成

Slide

课件生成

Beamer + 编译反馈

›

Subtitle

讲稿 / 焦点

视觉模型读课件

›

Cursor

时空定位

坐标 + 字词时间

›

Talker

声音 / 人物

配音 + 数字人

论文：候选布局渲染 → 视觉选择；按页并行生成数字人

项目：源文核对 → 讲稿审核 → 双阶段问答 → 可追溯重生成

网页布局搜索默认关闭；本地任务串行，讲稿API请求可并发。

模型按角色选择，型号可以替换

任务角色	论文设置	当前项目可用路线	负责什么
文字 / 课件	GPT-4.1[1]	qwen3.8-flash	原文 → 结构 / Beamer
视觉 / 讲稿	GPT-4.1[1]	qwen3-vl-plus	课件画面 → 口播 / 焦点
配音	F5-TTS	CosyVoice-v3.5-plus	口播 → 声音 / 时间戳
识别 / 对齐	WhisperX	Qwen3-ASR / ForcedAligner	真实音轨识别 / 本地对齐
光标定位	UI-TARS	PDF优先；Qwen3-VL / GUI-Owl	焦点 → 画面坐标
数字人	Hallo2 / FantasyTalking	MuseTalk / wan2.2-s2v	可选；新任务默认关闭
问答评价	Gemini-2.5-Flash[2]	独立 qa；qwen3-vl-plus	题库、材料 → 带证据的答案

[1] 论文VLM设置；[2] 论文VideoLLM设置。项目型号为代码预设 / 可选路线，非历史统一配置。

配置要能复现，也要能在执行前校验

单角色示例 · 不是完整任务JSON

```
"mode": "api"
"provider": "bailian"
"connection_id": "class-demo"
"model": "qwen3-vl-plus"
"parameters": {
    "temperature": 0.2
}
```

模式、连接、型号、参数
一起进入任务快照

文字 / 视觉 / qa：温度、输出上限
云配音语速：0.5–2；本地仅默认
讲稿并发：默认3，范围1–8
凭据失效：重新绑定后才能继续

温度示例不代表最优值；未设置参数时沿用接口默认。快照不保存密钥。

本地 / API：按资源和环节组合

API 路线

减轻本地生成模型加载压力
需要连接、材料上传和费用记录
可使用合成服务的字词时间戳

本地路线

准备权重、显存与运行环境
Qwen3-TTS / Qwen3-ASR
GUI-Owl定位 / MuseTalk数字人
文字、视觉、qa需要明确兼容服务

当前成片问答仍用本地 Qwen3-ASR；“百炼预设”是混合链路。

目录里可见型号 ≠ 当前适配器可执行；未实现路线在执行前拦截。

对齐靠真实时间轴，不靠平均分配

01

口播与真实音频

数字 / 公式先规范化

02

字词时间轴

云时间戳 / 本地对齐

03

字幕与光标

按词切句 / 空间定位

PDF文字定位优先；无指示时隐藏光标；字幕区与课件分离。

数字人开启才分段：目标18秒，严格 <20秒，检查采样连续且无重复。

配置选择，也会改变费用与重试成本

¥ 5.6694

第二章历史实测累计估算
122条去重记录 · 含失败恢复与Wan短片



策略：数字人默认关；自动重生成最多2次；有效缓存才复用。

历史标准价估算，非账户账单；不含本地算力、OSS与Codex/ImageGen。

论文用四种评价，回答四类问题

论文指标	测量目标	当前项目边界
Meta Similarity	内容 / 音色是否像真人材料	研究脚本保留，网页未完整集成
PresentArena	哪个视频更好？交换A/B顺序	建议用于版本对照，未完整集成
PresentQuiz	视频覆盖了多少原文知识?	已借鉴：讲稿 + 成片双阶段问答
IP Memory	肖像能否关联到视频与问题?	低优先级；不是隔天学习记忆

评价维度分开报告；事实、可读性、音质与学习成效仍需其他证据。

固定原文题库，避免“自己出题自己过关”

核对后的原文

细节题 + 理解题
默认20道四选一

固定题库

保存答案与原文摘录
人工复核题意与答案

仅依据产物答题

题目 + 选项 + 材料
不给答案和原文依据

有效正确题：答案正确，而且材料依据通过校验。

问答分数 = 有效正确题 / 总题数 × 100%；20题时，每题改变5个百分点。

讲稿评价与成片评价，使用不同证据

① 讲稿评价

只读取口播内容
检查是否覆盖固定原文题库
通过后才进入配音合片

② 成片评价

最终视频 → 完整音轨 → Qwen3-ASR
每60秒识别一段；抽取4–24张画面
评价真实音轨转写 + 实际画面

记录原文、材料、模型、题库及语言指纹；修改后旧结果失效。

抽帧不覆盖每个瞬间；ASR与评委可能出错。画面文字真实性仍依赖评委。

评分触发动作，异常回到人工复核

讲稿 ≥80% → 配音合片；未达到则审核 / 修改 / 显式人工继续。

<60%

自动纠错重生成

最多2次；新任务保留历史

60%–<80%

人工决策

选择接受或重新生成

≥80%

完成任务

教学结构门禁仍需通过

课堂判断：讲稿17/20，成片14/20，下一步应该怎么做?

异常 ≠ 0分：连接 / 识别失败时暂停。阈值是可调工程策略，非论文标准。

论文结果：模型答得好，真人仍更偏好人工

模型问答准确率 / %



灰：真人视频　绿：PaperTalker

人工偏好 / 1–5分

4.6　真人

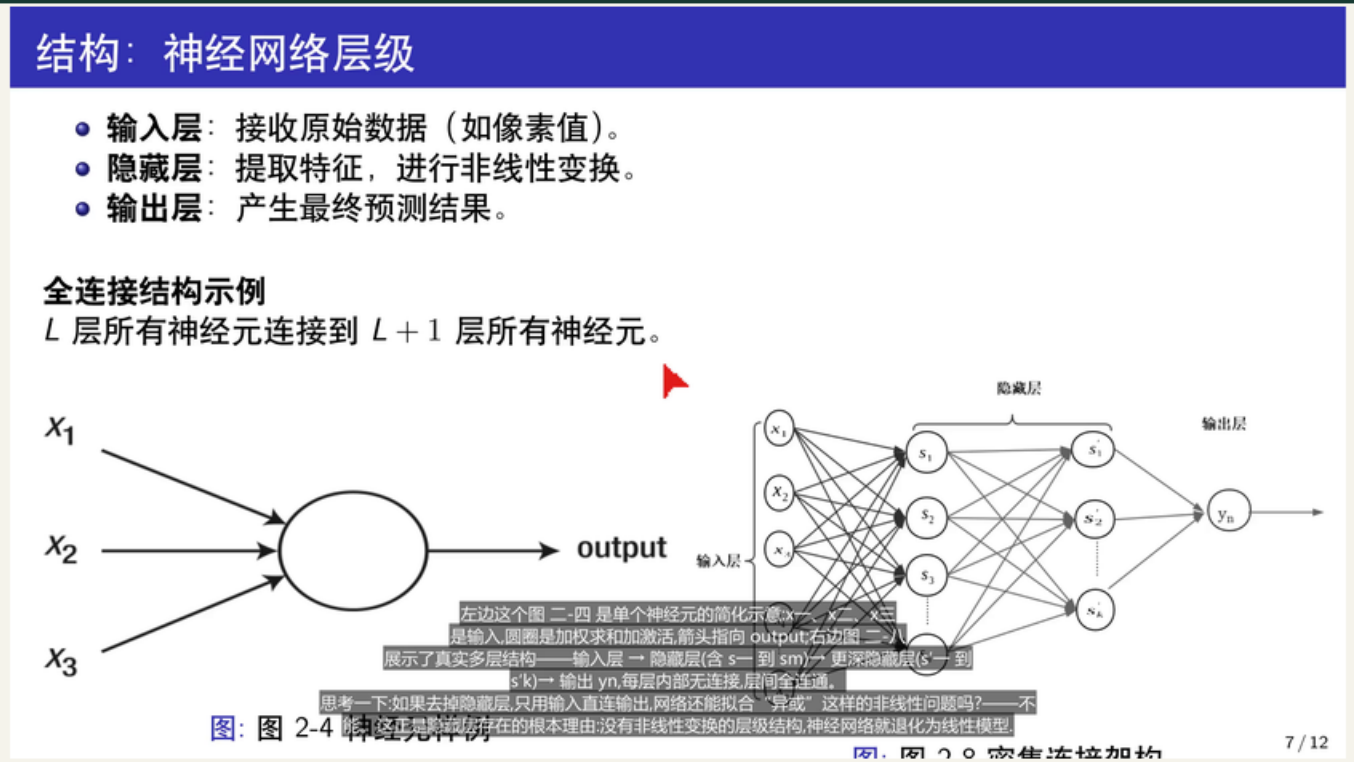
3.8　PaperTalker

抽取10篇论文，10名参与者
论文表2与图6；不同于本项目实测

问答覆盖率和观看偏好测量不同维度；不能据此宣称学生学习效果提升。

项目实测：技术跑通以后，仍要审教学

2026-10-08 历史样本 · 长字幕遮挡网络图



17页教材 → 12页课件
视频 25分24秒

人工辅助恢复后解码通过
教学交付历史评审约5/10
存在裁切、遮挡与事实问题

新版：流程已实现
问答16项离线回归通过
真实问答与学生效果待测

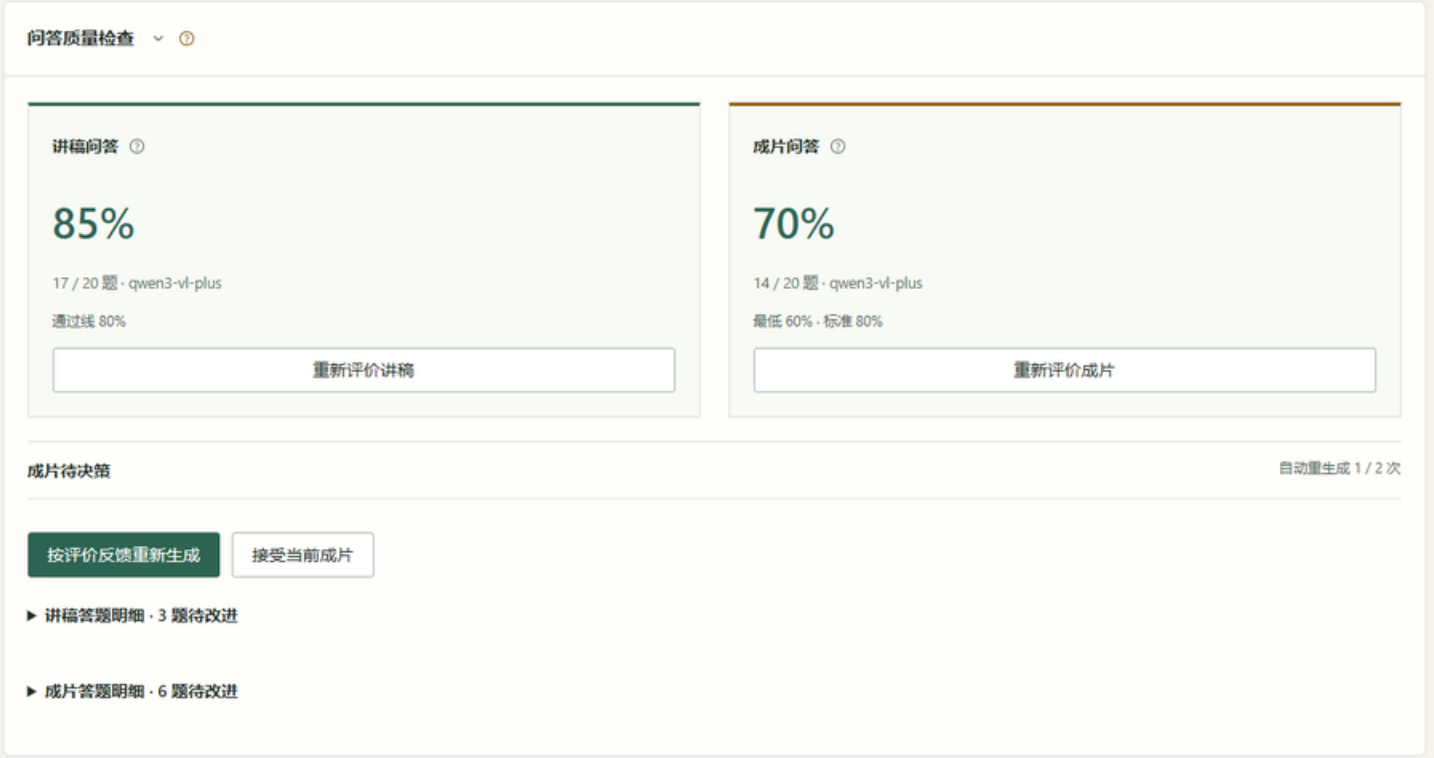
证据分开：历史成片暴露问题；新版本替身测试验证流程，不提供真实效果分数。

课堂演示：配置、证据、决定

1 看配置
2 查逐题证据

3 判断是否重做
4 原文复核错题

同一素材与题库
只改变一个因素
比较分数、可读性和费用



右侧85% / 70%为离线模拟截图，只展示界面，不是项目真实评价成绩。

下一步：把自动评分接回真实学习

模型配置让过程可复现
证据评价让结果可追溯

01 真实跑一次

人工复核题库
运行新版问答与听审

02 做版本对照

固定材料 / 题库 / 评委
每次只改一个因素

03 回到学习效果

学生观看前后测
课中错题讨论与反馈

从“生成成功”走向“教学可信”，仍需要真实课堂数据。

备用：常见提问与回答

问题	回答要点
为什么要多个模型?	能力与接口不同；便于替换、追溯和定位故障。
80%的依据是什么?	可调的工程默认，尚未通过学生学习效果标定。
题库摘录存在就正确?	只能验证出处存在；题意与答案仍需人工复核。
高分等于视频无错误?	题库与抽帧有限；仍需事实审核、连续观看和听审。
IP Memory是学习记忆?	论文做肖像—短片—问题关联，不是隔天测验。

本页为答辩备用，不计入15分钟。

备用：来源与复现入口

论文：Paper2Video: Automatic Video Generation from Scientific Papers
Zhu / Lin / Shou • arXiv:2510.05096v2 • 2025-10-09

P 论文§3.3 / §4 / §5 / 附录A.1
C / F / R 配置、默认值与角色执行
Q / D 问答实现与流程说明

H 第二章历史实测报告
L P1 / P2修复与离线验收
V 10月11日最新评价验收日志

完整相对路径、文件SHA256与逐页引用，见配套讲稿与 sources.json。

论文页码按PDF显示页码；主要实验数据见第8页表2与图6。